

Trabalho computacional - Política de Manutenção

Cleyton Nobre

Universidade Federal de Minas Gerais
Belo Horizonte/MG - Brasil
cleyton-nobre@ufmg.br

Thales Tenebra

Universidade Federal de Minas Gerais
Belo Horizonte/MG - Brasil
thalestenebra@ufmg.br

Thiago Fraga

Universidade Federal de Minas Gerais
Belo Horizonte/MG - Brasil
thi-fraga@ufmg.br

Abstract—Este trabalho aplica conceitos de Teoria da Decisão na definição de uma política ótima de manutenção para 500 equipamentos de uma empresa, buscando minimizar os custos de manutenção e os custos esperados de falha. O problema é modelado com base em dados reais e resolvido por meio de meta-heurísticas adaptadas, tanto em abordagens mono quanto multiobjetivo. A análise considera modelos de falha específicos por grupo de equipamentos e diferentes planos de manutenção. A escolha da melhor solução é feita com apoio de métodos multicritério e avaliação por hipervolume.

I. INTRODUÇÃO

A manutenção de equipamentos industriais é um fator crítico para a operação eficiente e segura de uma empresa. Decisões mal planejadas podem resultar em custos elevados, seja pela falha inesperada de ativos importantes ou pelo excesso de intervenções desnecessárias. Neste contexto, a otimização multi-objetivo oferece ferramentas fundamentais para apoiar o processo de escolha das melhores estratégias de manutenção, considerando múltiplos critérios e incertezas envolvidas.

Este trabalho computacional tem como objetivo aplicar os conceitos estudados na disciplina Teoria da Decisão à formulação e resolução de um problema de otimização relacionado à definição da política de manutenção de 500 equipamentos. A proposta envolve a construção de modelos matemáticos de otimização mono e multiobjetivo, implementação de algoritmos baseados em metaheurísticas e a aplicação de métodos multicritério para apoiar a escolha da melhor solução. O desempenho das abordagens propostas é avaliado por meio do indicador de hipervolume, que permite medir a qualidade das soluções obtidas em termos de convergência e diversidade.

Na Seção II apresentaremos a modelagem matemática do problema. Na qual é descrita a equação que o algoritmo otimizará, além da formulação matemática dos métodos de otimização.

Na Seção III é apresentada a modelagem do problema multiobjetivo utilizando o método da soma ponderada, transformando o problema multi em mono-objetivo.

A Seção IV traz a modelagem do problema multi-objetivo utilizando o método ε -restrito. Que utiliza do método das penalidade para transformar um problema de otimização restrito, em um problema irrestrito.

Na Seção VII, é apresentada a metodologia adotada para o desenvolvimento deste trabalho. São descritos os procedimentos utilizados, e as ferramentas aplicadas durante o desenvolvimento do trabalho.

A apresenta a formulação do método de avaliação da fronteira de pareto que será retornada pelos algoritmos desenvolvidos.

A Seção VIII traz os resultados obtidos a partir da aplicação da metodologia, acompanhados de análises e interpretações relevantes para a compreensão do desempenho e da validade da proposta.

Por fim, na Seção IX, são discutidas as conclusões do estudo, destacando as principais contribuições, limitações e sugestões para trabalhos futuros.

II. MODELAGEM MATEMÁTICA

A seguir, apresenta-se a modelagem matemática utilizada para o planejamento de manutenção preventiva de um conjunto de equipamentos, considerando custos de manutenção e falha ao longo de um horizonte de tempo pré-definido.

A. Conjuntos e Parâmetros

- $J = \{1, 2, 3\}$: Planos de manutenção ($j \in J$)
- I : Conjunto de equipamentos ($|I| = 500, i \in I$)
- $C = \{1, 2, 3, 4\}$: Clusters de equipamentos ($c \in C$)
- t_0^i : Idade atual do equipamento i (em anos)
- c_i : Cluster ao qual pertence o equipamento i
- f_i : Custo associado à falha do equipamento i
- k_j : Fator de risco do plano de manutenção j
- m_j : Custo de aplicar o plano j a um equipamento
- η_c : Parâmetro de escala (Weibull) para o cluster c
- β_c : Parâmetro de forma (Weibull) para o cluster c
- $p_{i,j}$: Probabilidade de falha do equipamento i sob o plano de manutenção j
- $\Delta t = 5$ anos: Horizonte de planejamento

B. Variável de decisão

$$x_{i,j} = \begin{cases} 1, & \text{se o equipamento } i \text{ realiza a manutenção } j \\ 0, & \text{Caso contrário} \end{cases} \quad (1)$$
$$\forall i \in I, \forall j \in J$$

C. Funções objetivo

a) Custo total de manutenção:

$$f_1(\hat{x}) = \min \sum_{i \in I} \sum_{j \in J} m_j \cdot x_{i,j} \quad (2)$$

b) Custo esperado de falha:

$$f_2(\hat{x}) = \min \sum_{i \in I} \sum_{j \in J} p_{i,j} \cdot x_{i,j} \cdot f_i \quad (3)$$

onde:

$$p_{i,j} = \frac{F_{c_i}(t_0^i + k_j \Delta t) - F_{c_i}(t_0^i)}{1 - F_{c_i}(t_0^i)} \quad (4)$$

$$F_{c_i}(t) = 1 - e^{-\left(\frac{t}{\eta_c}\right)^{\beta_c}} \quad (5)$$

D. *Surjeito a:*

$$\sum_{j \in J} x_{i,j} = 1 \quad \forall i \in I \quad \text{Integridade} \quad (6)$$

III. FORMULAÇÃO DA SOMA PONDERADA (P_w)

A abordagem da soma ponderada transforma um problema com múltiplos objetivos em um único problema escalar, por meio de uma combinação linear das funções objetivo.

A. *Problema Original*

Funções objetivos:

$$f_k(\hat{x}) \quad \forall k \in \{1, 2, \dots, n\} \quad (7)$$

Sujeito a:

$$g_j(\hat{x}) \leq 0 \quad \forall j \quad (8)$$

$$h_l(\hat{x}) = 0 \quad \forall l \quad (9)$$

$$\hat{x} \in \mathbb{R}^{\mathbb{D}} \quad (10)$$

Onde:

- $\hat{x}$ é o vetor de decisão.
- n é o numero de funções objetivo.
- $f_k(\hat{x})$ são as funções objetivo.
- $g_j(\hat{x})$ e $h_l(\hat{x})$ é o conjunto de restrições.
- Sendo $\mathbb{D}$ a dimensão de $\hat{x}$.

B. *Formulação da Soma Ponderada*

Minimizar:

$$F(x) = \sum_{i=1}^n w_i \cdot \hat{f}_i(x) \quad (11)$$

Sujeito a:

$$g_j(\hat{x}) \leq 0 \quad \forall j \quad (12)$$

$$h_l(\hat{x}) = 0 \quad \forall l \quad (13)$$

$$\sum_{i=1}^n w_i = 1 \quad (14)$$

$$w_i \geq 0, \forall i \quad (15)$$

C. *Normalização*

$$\hat{f}(\hat{x}) = \frac{f(\hat{x}) - \min f(\hat{x})}{\max f(\hat{x}) - \min f(\hat{x})} \quad (16)$$

Essa normalização é necessária para garantir que os objetivos estejam na mesma escala antes da aplicação da soma ponderada.

D. *Interpretação*

Os pesos w_i definem a importância relativa de cada objetivo. Ao variar os pesos, é possível gerar diferentes soluções de compromisso. A abordagem da soma ponderada pode não encontrar soluções em regiões não convexas do fronte de Pareto. A formulação por soma ponderada é simples e eficiente para problemas com fronte de Pareto convexo, permitindo controle sobre os trade-offs entre objetivos via pesos.

IV. FORMULAÇÃO ε -RESTRITO (P_ε)

A abordagem ε -restrita transforma um problema multiobjetivo em um problema de otimização com uma única função objetivo, tratando os demais objetivos como restrições com limites ε_i . Para transformar o problema descrito em Seção III.A em um problema possível de ser resolvido pelo método de ε -restrito seguimos os seguintes passos:

A. *Formulação ε -Restrita*

Função objetivo:

$$\min f_k(\hat{x}) \quad (17)$$

Sujeito a:

$$f_i(\hat{x}) \leq \varepsilon_i \quad \forall i \in \{1, \dots, n\} \quad i \neq \{k\} \quad (18)$$

$$g_j(\hat{x}) \leq 0 \quad \forall j \quad (19)$$

$$h_l(\hat{x}) = 0 \quad \forall l \quad (20)$$

Onde:

- $f_k(\hat{x})$ é o objetivo escolhido para otimização.
- Os demais objetivos $f_i(\hat{x})$ são tratados como restrições com limites ε_i .

V. FORMULAÇÃO DO HIPERVOLUME

O Hipervolume é um indicador de qualidade, também conhecido como s-metric, sendo amplamente utilizado em otimização multiobjetivo para avaliar a qualidade de um conjunto de soluções não-dominadas. Ele é capaz de mensurar simultaneamente convergência e diversidade das soluções.

Seja:

- P = conjunto de soluções não dominadas
- r = vetor de referência anti-utópico (nadir)
- $f(x)$ = vetor dos objetivos para a solução $\hat{x}$

O hipervolume (HV) é definido como:

$$HV(P) = \text{vol} \left(\bigcup_{x \in P} \prod_{i=1}^m [f_i(x), r_i] \right) \quad (21)$$

VI. ESCOLHA DE SOLUÇÃO

Para realizar a escolha da melhor solução para o problema, é necessário adotar uma abordagem estruturada de tomada de decisão, que envolva o uso de métodos e estratégias capazes de selecionar a alternativa mais adequada entre várias opções disponíveis. Essa escolha deve ser fundamentada em critérios ou objetivos previamente definidos. Tais abordagens são especialmente importantes em contextos complexos, onde há múltiplos critérios envolvidos ou presença de incertezas.

Nesse sentido, para apoiar a definição da solução a ser implementada, foram considerados dois critérios adicionais no processo de seleção.

A. *Critério de desbalanceamento do MTTF*

O presente critério mede o desbalanceamento na carga de falha esperada entre os três planos de manutenção. Na qual é calculado:

A média do tempo até a falha do equipamento i é:

$$\mu_i = \eta_{c_i} \cdot \gamma \left(1 + \frac{1}{\beta_{c_i}} \right) \quad (22)$$

A soma total dos tempos médios dos equipamentos alocados ao plano j é:

$$S_j = \sum_i^{|I|} x_{i,j} \cdot \mu_i \quad \forall j \in J \quad (23)$$

O desvio padrão dessas somas, para os três planos de manutenção, define a função:

$$f_3(x) = \text{std}(S_1, S_2, S_3) \quad (24)$$

Ela faz isso calculando, para cada plano de manutenção a soma dos tempos médios até a falha baseados na distribuição de Weibull dos equipamentos que foram alocados àquele plano;

Em seguida, calcula o desvio padrão dessas somas entre os três planos.

Esse critério foi pensando para avaliar se um conjunto de solução na falha ao mesmo tempo que outro, evitando que ambos falhe ao mesmo tempo.

B. Critério de entropia das soluções

O presente critério mede o nível de diversidade dos tipos de manutenção dentro de cada cluster de equipamentos. Na qual ela é definida como sendo:

A quantidade de equipamentos no cluster $c \in C$ que recebem o plano de manutenção $j \in J$ é:

$$n_{c,j} = \sum_{i \in I, c_i=c} x_{i,j} \quad (25)$$

A proporção de equipamentos no cluster c que recebem o plano j é:

$$p_{c,j} = \frac{n_{c,j}}{\sum_{j' \in J} n_{c,j'}} \quad (26)$$

A entropia do cluster c é:

$$H_c = - \sum_{j \in J} p_{c,j} \cdot \log_2(p_{c,j}) \quad (27)$$

A função retorna a entropia média dos clusters:

$$f_4(x) = \frac{1}{|C|} \sum_{c \in C} H_c \quad (28)$$

Alta entropia os três tipos de manutenção estão bem distribuídos dentro do cluster, com maior diversidade.

VII. METODOLOGIA

A presente seção tem como objetivo propor uma abordagem baseada em heurísticas para a alocação de planos de manutenção preventiva em equipamentos, considerando os custos envolvidos e o risco de falha, utilizado o algoritmo meta-heurístico GVNS.

O General Variable Neighborhood Search (GVNS) é uma meta-heurística avançada baseada no método Variable Neighborhood Search (VNS), projetada para resolver problemas complexos de otimização combinatória. Ele explora sistematicamente diferentes estruturas de vizinhança para escapar de ótimos locais e encontrar soluções de melhor qualidade.

Partido do pré-suposto acima o trabalho foi estruturado da seguinte conforme as seguintes etapas:

A. Leitura e Pré-processamento dos Dados

Para a resolução do problema foram carregados, três bases de dados, sendo elas:

- EquipDB.csv: contém o ID do equipamento, o tempo desde a última falha, o cluster ao qual pertence e o custo associado à falha.
- ClusterDB.csv: fornece os parâmetros da distribuição de Weibull (η e β) por cluster.
- MPDB.csv: lista os planos de manutenção com seus respectivos fatores de risco (k) e custos.

B. Modelagem Probabilística de Falha

Foi utilizada a função de distribuição acumulada de Weibull para calcular a probabilidade de falha acumulada $F(t)$ equação (5) e a probabilidade condicional de falha $P(t_0, \eta, \beta, k, \Delta t)$ Equação (4), com base no tempo desde a última falha, nos parâmetros da distribuição e no fator de risco de cada plano.

Para cada equipamento i e plano j , foi calculada a probabilidade condicional de falha utilizando a fórmula de Weibull fornecida nas equações (4), (5). Esses valores foram armazenados em uma matriz P_{ij} , representando o risco de falha caso o plano j seja aplicado ao equipamento i .

Na qual a distribuição Weibull é uma distribuição de probabilidade contínua muito usada em análise de confiabilidade, análise de sobrevivência, e em engenharia para modelar o tempo até a falha de um sistema ou componente.

C. Geração de Solução Inicial

Para alcançar uma convergência mais rápida um solução inicial X foi gerada utilizando um critério de criticidade, definido como o produto entre o custo de falha, a probabilidade de falha e o tempo desde a última falha. Dessa forma, os equipamentos foram ordenados por criticidade, e os planos de manutenção foram atribuídos da seguinte forma:

- 20% mais críticos: plano mais detalhado.
- 30% intermediários: plano médio.
- 50% menos críticos: sem manutenção.

D. Definição das Funções Objetivo

Partido da formulação matemática do problema duas funções objetivo foram consideradas:

- $f1$: Equação (2) minimiza o custo total de manutenção preventiva.
- $f2$: Equação (3) minimiza o custo esperado de falha, calculado como o produto entre a probabilidade de falha e o custo de falha.

E. Estrutura de Vizinhança

Três operadores de vizinhança foram implementados:

- `move`: altera aleatoriamente o plano de um equipamento.
- `double_move`: altera os planos de dois equipamentos distintos.
- `block_change`: altera os planos de um bloco de até 50 equipamentos consecutivos.

F. Heurística GVNS (General Variable Neighborhood Search)

A busca GVNS foi aplicada para cada função objetivo. A abordagem consiste em:

- 1) Gerar uma solução inicial baseada na criticidade.
- 2) Aplicar uma sequência de vizinhanças.
- 3) Realizar busca local a partir da vizinhança explorada.
- 4) Atualizar a solução caso haja melhoria.
- 5) Repetir por um número fixo de iterações.

G. Otimização via soma ponderada

A abordagem utilizada para aplicar a soma ponderada na resolução do problema multiobjetivo consistiu nos seguintes passos:

- 1) Seleção aleatória de um valor de $w \in [0, 1]$, representando o peso atribuído à função objetivo de custo de manutenção (f_1);
- 2) Normalização das funções f_1 e f_2 , de modo a garantir comparabilidade entre grandezas com escalas distintas;
- 3) Construção de uma nova função objetivo agregada por meio da fórmula:

$$F(x) = w \cdot \hat{f}_1(x) + (1 - w) \cdot \hat{f}_2(x) \quad (29)$$

onde $\hat{f}_1(x)$ e $\hat{f}_2(x)$ são as versões normalizadas de f_1 e f_2 , respectivamente;

- 4) Aplicação do algoritmo GVNS para otimizar a função agregada, utilizando as mesmas estruturas de vizinhança e critérios de busca local previamente definidos;

H. Otimização via ε -restrito

A abordagem utilizada para aplicar o método ε -restrito na resolução do problema multiobjetivo consistiu nos seguintes passos:

- 1) Escolha aleatória de uma das funções objetivo (f_1 ou f_2) para ser minimizada na iteração corrente;
- 2) Geração de um valor aleatório de ε dentro do intervalo observado da função que será tratada como restrição;
- 3) Construção de uma nova função objetivo penalizada da forma:

$$F(x) = f_{\min}(x) + \rho \cdot \max\{0, f_r(x) - \varepsilon\} \quad (30)$$

onde:

- $f_{\min}(x)$: representa a função escolhida para minimização (custos de manutenção ou custos de falha),
 - $f_r(x)$ é a função tratada como restrição,
 - ρ é um coeficiente de penalidade utilizado para penalizar violações da restrição ε ao qual foi escolhido arbitrariamente o valor de 100.
- 4) Aplicação do algoritmo GVNS para otimizar a função penalizada, com as mesmas estruturas de vizinhança e procedimentos de busca local.

I. Escolha de solução

Para a escolha das soluções, foram implementados dois algoritmos de apoio à tomada de decisão, com o objetivo de determinar quais alternativas são mais relevantes com base em múltiplos critérios. Entre esses critérios estão as próprias

funções objetivo (ver Seção Seção II), o critério de entropia da solução (ver Seção Seção VI.B) e o balanceamento das soluções em termos de MTTF (ver Seção Seção VI.A). Com base nesses critérios, os métodos ELECTRE I e PROMETHEE II foram utilizados para identificar a solução mais adequada para o problema em estudo.

J. Avaliação Experimental

Para avaliação do algoritmo GVNS em um problema mono-objetivo, ele foi executado 5 vezes para cada função objetivo (f_1 e f_2). Foram coletadas as seguintes métricas:

- Custo mínimo, máximo e desvio padrão das soluções encontradas.
- Curvas de convergência por iteração.

Para otimização multi objetivo o modelo foi executado 5 vezes com 20 iterações cada para poder encontrar uma fronteira de pareto de pontos no espaço multi-objetivo. A fronteira obtida em cada um dos métodos foi avaliada de acordo com o seu hipervolume.

VIII. RESULTADOS

Por se tratar de um método estocástico, o GVNS não garante a obtenção do ponto ótimo global das funções objetivo. Assim, o algoritmo foi executado 5 vezes para cada função objetivo, possibilitando a obtenção de soluções distintas em cada execução. Para análise dos resultados, foram registrados o menor e o maior valor encontrado, o desvio padrão das soluções obtidas e o gráfico de convergência do algoritmo em cada iteração.

A. Otimização mono-objetivo

Como ponto de referência, o melhor e o pior resultado para f_1 ocorrem, respectivamente, quando não realizamos manutenção em nenhum dos equipamentos — resultando em um custo de \$0 — e quando realizamos manutenção detalhada em todos os equipamentos, o que gera um custo de \$1000

Por sua vez, o melhor e o pior resultado para f_2 ocorrem, respectivamente, quando realizamos manutenção detalhada em todos os equipamentos — resultando em um custo esperado de \$1048,18 — e quando não realizamos manutenção em nenhum deles, o que gera um custo de \$1745,49.

Os resultados obtidos estão apresentados a seguir:

- f_1 : Custo total de manutenção
 - Mínimo: \$28,0
 - Máximo: \$40,0
 - Desvio Padrão: \$4,41
 - Gráfico de convergência:




Fig. 1: Convergência da função $f_1(\hat{x})$ com 5 iterações

- f_2 : Custo esperado de falha
 - ▶ Mínimo: \$1061,63
 - ▶ Máximo: \$1063,60
 - ▶ Desvio Padrão: \$0,65
 - ▶ Gráfico de convergência:




Fig. 2: Convergência da função $f_2(\hat{x})$ com 5 iterações

Analisando os resultados obtidos podemos perceber que as soluções encontradas são bastante próximas umas das outras, indicando grande estabilidade no algoritmo. Os gráficos mostram as diversas soluções que o algoritmo encontrou ao longo do seu processo de otimização até atingir um ponto suficientemente ótimo.

B. Fronteira Pareto

A fronteira de Pareto representa o equilíbrio (trade-off) entre o custo de manutenção (f_1) e o custo esperado de falha (f_2). Como o objetivo é minimizar ambos, os pontos mais desejáveis situam-se próximos ao canto inferior esquerdo do gráfico. Observa-se que, para valores baixos de f_1 , os valores

de f_2 tendem a ser elevados (em torno de 1700). Abaixo, ilustramos a fronteira de Pareto resultante da otimização utilizando duas formulações distintas: a soma ponderada, descrita na Seção Seção III, e o método ε -restrito, apresentado na Seção Seção IV.

a) Otimização via P_w :

A Figura Fig. 3 ilustra a fronteira de Pareto obtida a partir de cinco repetições da otimização com o algoritmo de soma ponderada. Observa-se que as fronteiras resultantes são bastante próximas entre si, o que indica uma boa consistência do algoritmo.




Fig. 3: Fronteira Pareto otimizada com P_w com 5 repetição

Além de que observamos que medida que o custo de manutenção aumenta, o custo esperado de falha diminui — o que é esperado: investir mais em manutenção reduz as falhas.

A fronteira de Pareto obtida via P_w boa convergência e diversidade nas soluções. Embora não tenha alcançado o ponto ótimo teórico, chegou relativamente próximo, especialmente nas soluções com maior custo de manutenção. Isso mostra que o método é eficaz para capturar o equilíbrio entre os objetivos conflitantes.

Para avaliar a qualidade do conjunto de soluções obtido, utilizamos a relação de hipervolume, descrito na equação (21), como métrica. Essa relação foi calculada a partir da aproximação da área dominada pelas soluções obtidas, ou seja acima da curva de Pareto, em relação à área total delimitada pelos pontos de referência utópico e nadir no espaço dos objetivos. Como resultado, obtivemos um valor de 0,617739, o que significa que aproximadamente 61,77% do espaço potencialmente dominável foi efetivamente coberto pelas soluções não dominadas encontradas.

Esse valor indica uma boa cobertura da frente de Pareto, sugerindo que o algoritmo de otimização conseguiu encontrar soluções bem distribuídas e relativamente próximas da frente ótima teórica.

b) Otimização via P_ε :

A Figura Fig. 4 ilustra a fronteira estimada após 5 repetições do algoritmo usando o método do ε -restrito. É possível observar que as fronteiras obtidas em cada repetição são

bastante similares, o que evidencia a robustez do algoritmo proposto.

Com essa figura é possível observar a que a medida que uma das funções é otimizada, a outra tende a aumentar — comportamento típico em problemas multiobjetivo com objetivos conflitantes, como é o caso do custo de manutenção e do custo esperado de falha. Isso reforça a coerência da modelagem e da implementação.




Fig. 4: Fronteira Pareto otimizada com P_ϵ com 5 repetição

A estratégia do ϵ -restrito mostrou-se eficiente em explorar diferentes regiões da fronteira de Pareto. Por restringir explicitamente uma das funções objetivo em cada execução, o método força o algoritmo a buscar soluções viáveis mesmo em áreas extremas do espaço de decisão, promovendo uma boa diversidade no conjunto final de soluções.

A avaliação do hipervolume foi novamente utilizada como métrica de qualidade, resultando em um valor de 0,638422. Esse valor indica que aproximadamente 63,84% do espaço potencialmente dominável foi coberto pelas soluções não dominadas obtidas. Embora ligeiramente superior ao valor alcançado pelo método P_w , o algoritmo pode variar, já que há uma aleatoriedade na escolha dos pesos de P_w e dos ϵ s de P_ϵ .

Portanto, o método P_ϵ demonstrou ser tão eficiente quanto P_w para encontrar soluções na fronteira pareto.

C. Escolha da solução

Para realizar a escolha da solução, foram utilizados dois métodos computacionais de apoio à decisão: o PROMETHEE II [1] e o ELECTRE II[2].

A adoção de métodos computacionais confere maior confiabilidade ao processo decisório, pois reduz vieses subjetivos comumente associados à decisão humana. Esses métodos são especialmente eficazes em problemas multicritério.

Para determinar a importância relativa de cada objetivo, foram atribuídos pesos às funções f_1 , f_2 , f_3 e f_4 , sendo esses valores respectivamente 0.35, 0.40, 0.10 e 0.15. Na qual esses

pesos refletem a relevância de cada critério na avaliação das soluções.

Com base na aplicação do método PROMETHEE II, foi obtido o seguinte resultado para a solução selecionada: f_1 : 724, f_2 : 1165.90 f_3 : 1221.37 e f_4 : 1.286.

Por sua vez para o método ELECTRE I, foi obtido o seguinte resultado para a solução selecionada: f_1 : 708, f_2 : 1170.24, f_3 : 1191.57 e f_4 : 1.307826.

Abaixo segue a análise da solução encontrada para cada método.

D. PROMETHEE II

A Fig. 5 apresenta um gráfico de dispersão onde cada ponto azul representa uma solução alternativa avaliada segundo os dois critérios. A alternativa destacada em vermelho foi classificada como a melhor solução segundo o método PROMETHEE II, considerando o equilíbrio entre os critérios.




Fig. 5: Escolha da solução usando o método PROMETHEE II

Essa alternativa representa o compromisso ótimo entre minimizar os custos de manutenção e os custos de falha, sendo preferida frente às demais opções no ranking final gerado pelo método.

A Fig. 6 exibe a composição das soluções escolhidas em termos de tipos de manutenção adotados, representados pelas cores azul, verde e laranja para os tipos 1, 2 e 3, respectivamente distribuídas entre os diferentes clusters de soluções 1, 2, 3 e 4.




Fig. 6: Gráfico de barra da distribuição de Tipos de Manutenção por Cluster usando o método PROMETHEE II

A diversidade de cores em cada cluster reflete a variação na alocação dos tipos de manutenção dentro das soluções, o que está diretamente relacionado à entropia do sistema. Soluções com distribuição mais heterogênea de tipos indicam maior entropia, sugerindo flexibilidade e adaptação a diferentes contextos operacionais.

E. ELECTRE I

A Fig. 7 mostra com as alternativas avaliadas pelo algoritmo ELECTRE I. A alternativa em vermelho foi classificada como a melhor solução pelo algoritmo,.




Fig. 7: Escolha da solução usando o método ELECTRE I

Essa alternativa foi a que obteve melhor sobreclassificação sobre as outras, além de não ter sido sobreclassificada por nenhuma outra alternativa. Para esse algoritmo, foi adotado um limiar de concordância, τ_c , de 0,6 e um limiar de discordância, τ_d , de 0,2.

A Fig. 8 exibe a composição das soluções escolhidas em termos de tipos de manutenção adotados, representados pelas cores azul, verde e laranja para os tipos 1, 2 e 3, respectivamente distribuídas entre os diferentes clusters de soluções 1, 2, 3 e 4.




Fig. 8: Gráfico de barra da distribuição de Tipos de Manutenção por Cluster usando o método ELECTRE I

F. Escolha de uma solução

As soluções encontradas pelos algoritmos são bem parecidas, tanto em valores dos critérios, quanto em variabilidade dos tipos de manutenção. Então como critério de desempate foi escolhida a solução com menor custo máximo, ou seja, a solução que tem menor valor da soma de f_1 e f_2 .

Para o método PROMETHEE II temos um custo total de \$1889,9 e, para o método ELECTRE I temos \$1878,24. Logo, a alternativa escolhida como plano de manutenção é a escolhida pelo método ELECTRE I.

IX. CONCLUSÃO

Este trabalho apresentou uma abordagem robusta e bem fundamentada para a definição de políticas ótimas de manutenção preventiva, integrando conceitos avançados de Teoria da Decisão, modelagem matemática, técnicas de otimização e métodos multicritério. A partir da aplicação de meta-heurísticas como o GVNS e da utilização de abordagens multiobjetivo — soma ponderada e ε -restrito — foi possível gerar soluções que equilibram de forma eficiente os custos de manutenção e os riscos de falha, mesmo diante da complexidade envolvida no gerenciamento de 500 equipamentos com diferentes perfis de risco.

Os resultados obtidos demonstraram que ambas as abordagens de otimização foram capazes de produzir soluções estáveis, diversas e próximas da fronteira de Pareto teórica, com cobertura expressiva do hipervolume. A adoção de critérios adicionais, como entropia e desbalanceamento de MTTF, possibilitou uma análise mais rica do desempenho das soluções, refletindo preocupações práticas relacionadas à resiliência e adaptabilidade do sistema de manutenção.

Por fim, a aplicação de métodos multicritério como ELECTRE I e PROMETHEE II permitiu a escolha sistemática da melhor solução, considerando simultaneamente múltiplos objetivos e preferências. A alternativa selecionada pelo método ELECTRE I demonstrou o melhor desempenho no critério de custo combinado, reforçando a importância da análise integrada de múltiplas dimensões do problema.

A realização deste trabalho contribuiu para o aprofundamento do conhecimento prático em técnicas de otimização aplicadas à área de manutenção, além de fortalecer a compre-

ensão sobre os desafios e decisões envolvidas na construção de modelos computacionais voltados à engenharia.

REFERÊNCIAS

- [1] M. Bertoncini, A. Boggio, F. Dell'Anna, C. Becchio, e M. Bottero, «An application of the PROMETHEE II method for the comparison of energy requalification strategies to design Post-Carbon Cities», *AIMS Energy*, vol. 10, n.º 4, pp. 553–581, 2022, doi: 10.3934/energy.2022028.
- [2] L. Maystre, J. Pictet, J. Simos, e B. Roy, *Méthodes multicritères ELECTRE: description, conseils pratiques et cas d'application à la gestion environnementale*. em Collection Gérer l'environnement. Presses polytechniques et universitaires romandes, 1994. [Online]. Disponível em: <https://books.google.com.br/books?id=KD5uY0M8k7oC>
- [3] L. de Souza Batista, «Notas de aula da disciplina de Teoria da Decisão». 2025.